

Centinela del Río: línea base estratégica de un sistema de alerta temprana de calidad del agua

Informe técnico-ético · Proyecto Centinela · Fase 1 (Módulo 1)
Autores: Camilo Chiquiza · Brian Lerma · Luz Villarraga

1. El problema y el cliente

El acceso a agua segura es un servicio crítico para cualquier comunidad. Este trabajo construye la **línea base** de un sistema de alerta temprana —el **Centinela del Río**— que anticipa, con un **día de antelación**, si el agua de una fuente de abastecimiento quedará **fuera del rango de pH seguro para consumo humano** (6,5 a 8,5 unidades, guías de la Organización Mundial de la Salud). El destinatario es la **junta administradora de un acueducto comunitario rural (JAAR)**, sin formación técnica en datos, que necesita una señal clara y oportuna para reforzar el monitoreo, ajustar la dosificación o suspender la captación antes de que la población consuma agua fuera de norma. El problema se aborda como **clasificación binaria**: cada día se predice **riesgo** (1) o **condición segura** (0) para la jornada siguiente. Esta fase es la primera de tres: aquí se levanta la línea base con un MLP tabular; la Fase 2 incorporará imagen (CNN) y serie (RNN/LSTM/GRU) con fusión multimodal, y la Fase 3 industrializará el sistema con GPU, precisión mixta y despliegue en campo.

2. Los datos y su preparación

Se utilizó el conjunto *Water Quality Prediction* del UCI Machine Learning Repository (Zhao, 2019), licencia Creative Commons Attribution 4.0. Reúne mediciones diarias de **37 estaciones** de monitoreo en Georgia (EE. UU.), con **once índices físico-químicos** por estación (máximos, mínimos y medias de oxígeno disuelto, temperatura y conductancia específica, más el pH del día). La tarea original es de regresión; aquí se **reencuadró** a una alerta binaria. La serie espacio-temporal se **aplanó a una tabla de 26.011 registros** (cada fila es un par día-estación), y el pH del día siguiente se binarizó respecto al rango seguro. Los datos venían normalizados ($\text{pH} \div 10$), por lo que el umbral se aplicó en la escala correspondiente. No hubo valores faltantes. El conjunto resultó **moderadamente desbalanceado** (~36 % de riesgo, casi siempre por **acidificación**, $\text{pH} < 6,5$). La partición respetó el **orden temporal** original (entrenamiento 2016, prueba hasta 2018), reservando los días más recientes como validación para evitar fuga de información.

3. El modelo estratégico y su entrenamiento

La línea base es un **Perceptrón Multicapa profundo** de **tres capas ocultas** (64-32-16 neuronas) con **normalización por lotes (BatchNorm)**, activación ReLU y Dropout. La salida es un único valor (logit) que al evaluar se convierte en probabilidad. Para hacer el modelo más **predecible y robusto** se emplearon cinco mecanismos: (i) **entropía cruzada binaria con *pos_weight***, que penaliza más los falsos negativos —el error costoso en alerta temprana—; (ii) **regularización L2 (*weight decay*)** y (iii) **Dropout** contra el sobreajuste; (iv) un **planificador de tasa de aprendizaje** que la reduce cuando la validación se estanca; y (v) **parada temprana (*early stopping*)**, que conserva el modelo de la mejor época de validación. El entrenamiento usó el optimizador Adam y semilla fija para reproducibilidad. El efecto de esta regularización sobre el aprendizaje se ilustra más adelante (Figura 2).

4. Resultados: qué tan bien avisa el Centinela

Esta sección está pensada para el **cliente** (la JAAR): traduce el desempeño del modelo a una pregunta concreta —de cada situación de riesgo real, ¿el sistema avisó?— antes de entrar en el detalle técnico. Sobre el conjunto de prueba (10.397 días-estación nunca vistos), el resultado se resume en la Figura 1.

De cada situación de riesgo real, ¿el Centinela avisó?




Figura 1 (explicativa, para el cliente). De cada situación, el Centinela detectó 3.597 riesgos a tiempo, generó 877 falsas alarmas y dejó pasar 435 riesgos sin avisar. El color resalta solo el error que más importa vigilar (no avisar habiendo riesgo); el resto se mantiene en tonos neutros para no competir por la atención.

El modelo es además **estable y reproducible**: aprende sin memorizar los datos de entrenamiento, como muestra la Figura 2.




Figura 2 (explicativa). Las pérdidas de entrenamiento y validación bajan juntas y se estabilizan: si el modelo memorizara, la línea de validación subiría. La parada temprana conserva la mejor época (122).

Para el **equipo técnico**, las métricas formales confirman la calidad del modelo: **exactitud 87,4 %**, **ROC-AUC 0,955** y **PR-AUC 0,929**. La Tabla 1 detalla el desempeño por clase y la Figura 3 reúne las curvas ROC y Precisión-Recall.

Clase	Precisión	Recall	F1	Apoyo
Seguro (0)	0,927	0,862	0,893	6.365
Riesgo (1)	0,804	0,892	0,846	4.032
Exactitud / ROC-AUC	0,874	0,955	—	10.397

Tabla 1. Métricas por clase en prueba (umbral 0,5). La última fila reporta exactitud global y ROC-AUC.




Figura 3 (exploratoria, para el equipo técnico). Curvas ROC y Precisión-Recall. El AUC de 0,955 y el AP de 0,929 confirman que el modelo separa bien las clases incluso con desbalance.

5. Análisis de errores y reflexión ética

Un **falso negativo** —decir “agua segura” cuando el pH quedará fuera de norma— implica consumo de agua insegura **sin prevención**; su costo recae sobre la **salud pública** y es el más grave. Un **falso positivo** —alertar sin causa— genera costos de operación y, repetido, erosiona la **confianza**. El sistema permite decidir el equilibrio mediante el **umbral** de decisión, como muestra la Tabla 2.

Umbral	Falsos negativos	Falsos positivos	Recall (Riesgo)
0,57 (óptimo F1)	597	644	0,852
0,50 (por defecto)	435	877	0,892
0,40	204	1.288	0,949
0,30	133	1.508	0,967
0,20	93	1.708	0,977

Tabla 2. Efecto del umbral. Bajarlo reduce falsos negativos (de 435 a 93) a cambio de más falsos positivos.

Esta elección se enmarca en el **Marco Ético para la IA en Colombia** (Minciencias, 2021): qué error privilegiar debe responder al impacto sobre las personas, con transparencia ante un cliente no especializado. Para la JAAR, aceptar algunas alertas de más a cambio de no dejar pasar riesgos reales es una decisión razonable. Se declara una **limitación**: los datos provienen de Georgia (EE. UU.); trasladar el modelo a una fuente colombiana exige **validación local**. El sistema es una **ayuda a la decisión**, no un sustituto del muestreo de laboratorio.

6. Conclusión y continuidad

La línea base estratégica entrega un modelo con **ROC-AUC de 0,955** y **recall de riesgo de 0,89**, con entrenamiento estable y reproducible (BatchNorm, weight decay, scheduler, early stopping, semilla fija). En la **Fase 2**, la serie temporal aquí aplanada evolucionará a una arquitectura recurrente nativa (RNN/LSTM/GRU) y se incorporará la imagen (CNN) mediante fusión multimodal; la **Fase 3** llevará el Centinela a un despliegue *offline* en campo con GPU y precisión mixta.

7. Log de decisiones de visualización (auditable)

Siguiendo el enfoque de visualización del curso, las gráficas se diseñaron distinguiendo **exploración** (para el equipo técnico) de **explicación** (para el cliente), y se registran aquí las decisiones de diseño para que sean auditables.

Criterio	Decisión de diseño
#Audiencia / #Explicación	La Figura 1 traduce la matriz de confusión a una pregunta del cliente (“¿avisó el Centinela?”) con categorías en lenguaje natural, en vez de “verdaderos/falsos positivos”.
#Jerarquía / #Preatentivo	El color se reserva para el foco: verde = acierto, rojo = el error costoso, gris = lo secundario (falsas alarmas). Así el ojo va primero a lo que importa (Few, 2012).

#CargaCognitiva	Se evitó el mapa de calor de correlaciones en el informe (alta carga para audiencia no técnica); queda en el notebook como material exploratorio (Munzner, 2014).
#ÉticaVisual	Ejes sin truncar y sin efectos 3D; no se comparan pérdidas en escalas distintas. La Figura 2 contrasta entrenamiento vs. validación del mismo modelo, que es la comparación honesta (Cairo, 2019).
#EtiquetadoDirecto	Las series se rotulan al final de cada línea en lugar de usar leyendas separadas, reduciendo el salto de lectura (Nussbaumer Knaflic, 2015).

Tabla 3. Log auditable de decisiones de visualización, con los criterios y referentes del curso.

Referencias

- Cairo, A. (2019). *How charts lie: Getting smarter about visual information*. W. W. Norton.
- Few, S. (2012). *Show me the numbers: Designing tables and graphs to enlighten* (2.^a ed.). Analytics Press.
- Ministerio de Ciencia, Tecnología e Innovación. (2021). *Marco ético para la inteligencia artificial en Colombia*. Minciencias.
- Munzner, T. (2014). *Visualization analysis and design*. CRC Press.
- Nussbaumer Knaflic, C. (2015). *Storytelling with data: A data visualization guide for business professionals*. Wiley.
- Organización Mundial de la Salud. (2022). *Guidelines for drinking-water quality* (4.^a ed.). OMS.
- Zhao, L. (2019). *Water Quality Prediction* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.1145/3339823>